

Gymnázium Christiana Dopplera, Zborovská 45, Praha 5

ROČNÍKOVÁ PRÁCE  
**Regresní neuronové sítě**

Vypracoval: Lukáš Čaha  
Třída: 8.M  
Školní rok: 2017/2018  
Seminář: Seminář z programování

Prohlašuji, že jsem svou ročníkovou práci napsal samostatně a výhradně s použitím citovaných pramenů. Souhlasím s využíváním práce na Gymnáziu Christiana Dopplera pro studijní účely.

V Praze dne 18. prosince 2017

Lukáš Čaha

# Obsah

<b>1</b>	<b>Úvod</b>	<b>3</b>
<b>2</b>	<b>Základní pojmy</b>	<b>4</b>
2.1	Neuron . . . . .	4
2.1.1	Jádro . . . . .	4
2.1.2	Synapse . . . . .	4
2.2	Síť . . . . .	4
2.3	Pohyb dat . . . . .	5
2.3.1	Vstup . . . . .	5
2.3.2	Výstup . . . . .	5
<b>3</b>	<b>Vstup</b>	<b>6</b>
3.1	Design vstupní vrstvy . . . . .	6
3.1.1	Velikost vrstvy . . . . .	6
3.2	Scaling . . . . .	6
3.3	Data . . . . .	6
<b>4</b>	<b>Forward-propagation</b>	<b>7</b>
4.1	Typy sítí . . . . .	7
4.1.1	Normální . . . . .	7
4.1.2	Deep learning . . . . .	7
<b>5</b>	<b>Back-propagation</b>	<b>8</b>
5.1	Loss function . . . . .	8
<b>6</b>	<b>Praktická práce s PC</b>	<b>9</b>
6.1	Jazyk . . . . .	9
6.1.1	Vývojové prostředí . . . . .	9
6.1.2	Knihovny . . . . .	9
6.2	Git . . . . .	9
<b>7</b>	<b>Závěr</b>	<b>10</b>
	<b>Literatura</b>	<b>11</b>
	<b>Přílohy</b>	<b>12</b>

# 1. Úvod

Ve světě se nachází mnoho dat v mnoha podobách a v dnešní době se dostáváme do bodu, kdy nestačíme všechny třídit a využívat na 100 %.

Neuronové sítě jsou vrcholem lidské práce v oblasti informačních technologií. Mohl bych je přirovnat k lidskému mozku. A důvodem proč je zde zmiňuji je právě jejich všestranost. Sítí můžeme pouštět dva typy dat. Jedak lidmi vyhodnocené, a poté nevyhodnocené u nichž budu chtít výsledek. Neuronové sítě se podle prvního typu dat naučí jaká je souvislost mezi vstupem a výstupem a pak můžou přibližně určit výstupy dat druhého typu. Pokud byla v první řadě síť správně designovaná můžeme očekávat výsledky s poměrně velikou přesností a rychlostí zpracování, na jakou jsem zvyklí u počítačů.

Touto prací bych chtěl rozebrat neuronové sítě na úroveň pochopitelnou i pro středoškoláky, kteří by chtěli začít se strojovým učením, což je obor zahrnující moderní způsoby práce s umělou inteligencí.

## 2. Základní pojmy

### 2.1 Neuron

#### 2.1.1 Jádro

**Aktivace** je hodnota mezi nulou a jedničkou ( $a = 0.73$ ). Tahle hodnota určuje míru zapnutosti neuronu. Více aktivované neurony mohou mít větší vliv na neurony v síti přímo následující. Aktivace neuronů jsou závislé na datech, takže není možné měnit jejich hodnoty přímo.

**Normalizační funkce** upravuje příchozí signály, tak aby následně vytvořená hodnota zapadala do rozmezí aktivací. Přijdou-li do neuronu 4 signály všechny s maximální hodnotou, bude aktivace neuronu velmi blízko 1.

#### 2.1.2 Synapse

**Synapse** je spojení mezi dvěma neurony. Toto spojení zajišťuje, že aktivace neuronu v síti je závislá na aktivacích předchozích neuronů.

**Váha** ovlivňuje spoje mezi neurony. Váhy spojení tvoří dohromady povahu sítě. Z libovolných vstupních dat můžeme upravováním síly spojení (synapsí) vyvodit libovolné výstupní data.

### 2.2 Síť

Síť se skládá z několika vrstev, které jsou navzájem propojené.

**Vrstva** je několik neuronů, které se navzájem neovlivňují, ale jsou ovlivněny stejnými neurony a zároveň ovlivňují stejné neurony.

**Bias** je míra vlivu nezávislého na datech. Tato externí síla se stará o vyrovnaní sítě s menším počtem neuronů a tím uspořídá výpočetní výkon. V překladu je bias šum, který rozostřuje data, aby se výsledná síť nepřizpůsobila až příliš moc trénovacím datům.

## 2.3 Pohyb dat

### 2.3.1 Vstup

#### Typy vstupních dat

**Trénovací data** jsou data u nichž používáme vstupy i výstupy pro vylepšování sítě. Pokud výsledná síť uvidí znovu tato data bude na nich mít mnohem lepší výsledky, jelikož je trénovaná speciálně na tyto data a až jako vedlejší produkt je trénink na data podobná.

**Testovací data** je soubor vstupů, u nichž je známý i výsledek. Ten ale nikdy není ukázán síti, slouží totiž pro porovnání výsledku sítě s pravidlým výsledkem. Takto získává uživatel statistiky o kvalitě sítě.

**Produkční data** jsou důvod proč síť vůbec programujeme. Tyto data dostává síť během běžného používání a počítá k nim výsledky. Není však možnost určit jak by tyto výsledky měli vyjít, a proto nám už zbývá pouze doufat, že síť funguje jak popisuje teorie.

**Scaling** je metoda upravení hodnot z našich vstupních dat, tak aby v síti tato data vystupovala pouze jako aktivace. Dobrým příkladem je vstupní hodnota věk. V našich datech se vyskytuje člověk s maximální věkem 100 a minimálním 0. Odpovídající hodnoty aktivace potom budou  $100 \rightarrow 1.0$  a  $0 \rightarrow 0.0$ .

### 2.3.2 Výstup

**Back-scaling** je forma získání dat zpět z neuronové sítě. Pokud zrovna trénujeme, není nutné data získávat a pak je porovnávat s očekávanými výsledky, lepší způsob je očekávané výsledky převést na jazyk, kterým komunikuje síť. Tímto samozřejmě myslím použít scaling a převést výsledek na hodnotu mezi nulou a jedničkou.

## 3. Vstup

### 3.1 Design vstupní vrstvy

#### 3.1.1 Velikost vrstvy

Do vstupní vrstvy musíme dát dostatečné množství neuronů, aby mohli obsáhnout všechny důležité informace. Pokud budu například používat jako data obrázky o velikosti 28x28px, tak vhodný počet vstupních neuronů je 784, takto neztratím žádná data a dokonce budou mít takhle všechny pixely rovnocenný vliv. Pokud budu, ale používat jako data databázi s údaji o osobě, bude mi stačit neuronů zhruba stejný počet jako je sloupců v databázi.

### 3.2 Scaling

Jak již dobře víme, scaling je používán na získání hodnot mezi 0 a 1 ze vstupních dat. Naším vstupním číslem by síť totiž nemusela rozumět hned od začátku, jelikož se věk uvádí v řádu desítek, ale výplaty dosahují přibližně o 4 řády více. Až později pochopíme jak funguje teoretické učení sítě zjistíme, že se tomuto kroku můžeme vyhnout, avšak z praktických zkušeností pak usoudíme, že scaling je docela užitečný krok.

### 3.3 Data

U začátku designování a programování sítě stojí většinou nějaká data. Dříve u vymýšlení třídících algoritmů nám pomáhalo znát jak tato data vypadají. Tato znalost je u neuronových sítí naprosto zásadní. Budu-li trénovat síť míchat barvy musím opravdu dávat na vstup pravdivé výsledky míchání barev. Když se později poohlédneme za cestou od začátku do vytrénované sítě uvidíme, že dvě stejné sítě mohou být vytrénovány na dvě různé činnosti. Celkově bych to shnul upraveným příslovím: "Síť nepadá daleko od dat."

#### 3.3.1 Trénovací

Tento pojem již známe. Pojďme se tedy podívat na příklad míchání barev. Na trénovacích datech obzvlášť záleží. Musíme z existujících údajů tedy vybrat co nejvíc náhodně vzorky, jejichž smíchání bylo ovlivněno co nejvíce faktory. Jednoduše pokud si vyberu na trénování pouze temné barvy, nemůžu potom očekávat, že síť správně smíchá dvě světlé barvy.

#### 3.3.2 Testovací

Právě na těchto datech se uvidí, zda byly dosavadní kroky provedené úspěšně. Dosavadní kroky myslím celý postup, jelikož testovací data přichází skoro až na konci vývoje sítě.

Jsou to právě tyto data, která nám oznámí jak dobře jsme odvedli práci trénování.



## 4. Forward-propagation

### 4.1 Typy sítí

#### 4.1.1 Normální

#### 4.1.2 Deep learning

## 5. Back-propagation

### 5.1 Loss function

## 6. Praktická práce s PC

### 6.1 Jazyk

Jako vývojový jazyk jsem si zvolil Python. Konkrétně používám verzi 3.6.3 na operačním systému Windows 7 64-bit. Tento jazyk jsem si zvolil především, protože je v oboru výrazně preferovaný. Tomu odpovídá i množství knihoven, které pro python v oblasti strojového učení vzniklo.

#### 6.1.1 Vývojové prostředí

Pro vývoj používám NotePad++. IDE zvýrazňuje klíčová slova ve většině jazyků a není komplikované.

#### 6.1.2 Knihovny

Knihovny usnadňují práci s programem. Můžeme si je představit právě jako knihy z knihovny plné funkcí, které jsou většinou velmi jednoduché, ale i přes to vyžadují čas na vytvoření a organizaci zdrojových souborů. Navíc jsou dost často optimalizované na to co dělají.

**NumPy** poskytuje značné množství jednoduchých matematických operací a funkcí, ze kterých je strojové učení složené. Hlavní funkce je pro mne násobení matic, kterou je možné rychle vyhodnocovat forward-propagation.

### 6.2 Git

Pro zálohování a verzování používám Git.

## 7. Závěr

Toto je závěr mé ročníkové práce.

# Literatura

- [1] Birge J. R., Wets R. J.-B. (1987): Computing bounds for stochastic programming problems by means of a generalized moment problem. *Mathematics of Operations Research* **12**, 149-162.

# Přílohy